

Artificial intelligence in the steel industry

Dávid Firda

Technická Univerzity v Košiciach
Fakulta elektrotechniky a informatiky

david.firda@student.tuke.sk

Abstract—Tento prehľadový článok sa zaoberá štúdiou, ktorá aplikovala umelé neurónové siete a integrovaný optimalizačný modul na úpravu parametrov procesu vo výrobe ocele. Štúdia rozšírila tento rámec na širšie použitie v oblasti výroby a spracovania materiálov. Konkrétne sa v nej prezentuje príklad optimalizácie procesných parametrov pri kontinuálnej odlievaní ocele s využitím odborných poznatkov a vyvinutého systému. Výsledky naznačujú potenciálne zlepšenie efektivity a kvality výrobných procesov v oceliarskom priemysle prostredníctvom využitia umelej neurónovej siete a optimalizačných postupov. Tento prehľadový článok poskytuje hodnotný prehľad a analýzu tejto štúdie.

Index Terms—Artificial Intelligence, Artificial neural networks, steel manufacturing, optimization,

I. ÚVOD

V súčasnom priemysle je neustále rastúci dopyt po efektívnych spôsoboch optimalizácie výrobných procesov s cieľom dosiahnuť požadované výsledky a parametre [1]. V tomto kontexte sa uplatňuje využitie umelej neurónovej siete a integrovaných optimalizačných modulov na zlepšenie procesov výroby ocele. Tieto moderné technológie umožňujú presnejšie modelovanie, predikciu a optimalizáciu procesov na základe získaných dát a odborných poznatkov.

V kontexte tohto prehľadového článku sa pozornosť sústreďuje na aplikáciu umelej neurónovej siete a optimalizačných postupov pri kontinuálnom odlievaní ocele s cieľom dosiahnuť efektívnejšiu výrobu s požadovanými vlastnosťami materiálu. Štúdia sa sústreďuje na vývoj a implementáciu rámca, ktorý umožňuje modelovanie a optimalizáciu procesov v oceliarskom priemysle prostredníctvom využitia moderných technológií založených na umelej inteligencii [2].

V nasledujúcich častiach tohto prehľadového článku sa bližšie pozrieme na aplikáciu umelej neurónovej siete a integrovaných optimalizačných modulov v procese výroby ocele, ako aj na dosiahnuté výsledky a potenciálne výhody týchto technológií pre priemyselné aplikácie.

II. IMPLEMENTÁCIA SOFTVÉROVÉHO RÁMCA PRE MODELOVANIE A OPTIMALIZÁCIU NEURÓNOVÝCH SIETÍ

Optimalizačná časť tohto rámca bola navrhnutá ako samostatný optimalizačný systém, ktorého vývoj bol zameraný na implementáciu knižnice optimalizačných techník vhodných pre riešenie priemyselných problémov. Tento

systém využíva numerické simulácie s vysokou výpočtovou náročnosťou a často s prítomnosťou značného množstva numerického šumu. Na zabezpečenie efektívnej konvergenzie a minimalizácie výpočtových nákladov sa využívajú adaptívne stratégie aproximácie a vzorkovania odozvy [3].

Cieľom je dosiahnuť jednotný prístup k riešeniu rôznych typov optimalizačných problémov v priemyselných aplikáciách. Aby sa zabezpečilo rýchle prispôbienie parametrov procesu podľa požiadaviek zákazníka, je v súčasnosti skúmaná alternatívna metóda aproximácie odozvy systému, ktorá sa opiera o neurónové siete [4]. Tento prístup umožňuje vyhodnocovanie aproximovanej odozvy v dvoch samostatných etapách - tréningu a aproximácie - a poskytuje rýchlejšie výpočty pri ľubovoľných nastaveniach vstupných parametrov.




Fig. 1. A) Zostavenie aproximačného modelu tréningom siete na existujúcich údajoch. B) Predikcia na základe už natrénovanej siete. [5]

Získavanie dát z komplexných systémov môže často naraziť na nepresnosti alebo poškodenia v dôsledku praktických obmedzení v procesoch získavania. Plánovanie vzorkovania odozvy vopred je zriedka možné, keďže sa musí prispôbiť výrobným plánom vo fabrike. V dôsledku toho môže byť dostupná informácia nevyhovujúca v niektorých častiach priestoru parametrov, čo komplikuje úlohu dosiahnutia spoľahlivej aproximácie odozvy.

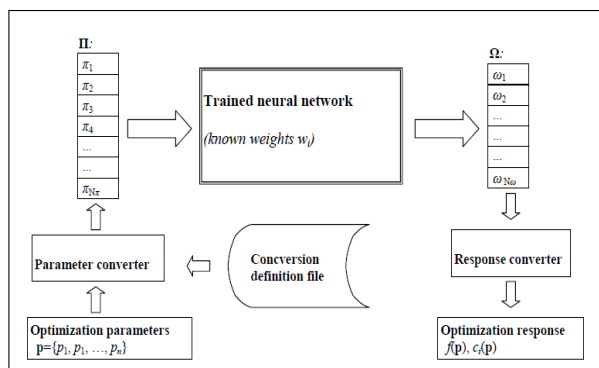


Fig. 2. Integrácia aproximovanej odozvy do optimalizačného procesu: Vyhodnotenie funkcií odozvy. [5]

Nakol'ko hlavným cieľom je optimalizovať procesné parametre s ohľadom na stanovené ciele, je nevyhnutné aproximovať závislosť objektívnych a obmedzujúcich funkcií od optimalizačných parametrov. Softvérový systém popísaný v tejto štúdii [1] poskytuje podporu aj pre alternatívny prístup, kde je neurónová sieť trébovaná na dátach obsahujúcich všetky vplyvné parametre procesu a určitý počet hrubých výstupných hodnôt vzorkovaných v procese. Vytvorením mapovania medzi optimalizačnými a vstupnými parametrami neurónových sietí a medzi hrubými aproximovanými výstupmi a vyššími úrovňami odoziev (ako sú obmedzujúce a objektívne funkcie) je možné riešiť rozmanité optimalizačné úlohy s použitím rovnakej natrénovanej siete, pričom nie je nutné opakovať trébovací proces pri zmene definície problému.

III. POPIS PROCESU VÝROBY OCELE

Použitie uvedeného rámca na optimalizáciu procesných parametrov kontinuálneho odlievania [6] je zamerané na dosiahnutie požadovanej kvality vyrábaných ocelových blokov. Detailný opis priemyselného procesu, ktorý bol študovaný, je uvedený v článku [1].




Fig. 3. Proces výroby ocele. [1]

V tomto procese roztavená oceľ preteká z kade do formy, kde začína tuhnúť. Počas tohto procesu sa čiastočne tuhnutá oceľový blok prepravuje z formy pomocou série podporných valcov. Blok je ohýbaný do horizontálnej

polohy a tuhne od povrchu smerom k vnútru, pričom sa riadi postrekom chladenia a chladením valcov. Na záver tejto fázy sa blok odreže a pripraví na ďalšie úpravy.

Pre hladký priebeh procesu a minimalizáciu defektov výstupného materiálu musia byť splnené určité požiadavky. Na výstupe z formy musí byť tuhnutá koža dostatočne hrubá na to, aby sa zabránilo roztrhnutiu bloku, čo môže obmedziť povolenú rýchlosť liatia. Teplota povrchu bloku v oblasti ohýbania musí byť dostatočne vysoká, aby sa zabránilo prasknutiu tuhnejšej kože. Naopak, prierez bloku musí byť úplne tuhý pred miestom odrezania, aby sa predišlo výronu roztaveného kovu. Tieto procesné podmienky sú výrazne ovplyvňované teplotou roztaveného ocele, rýchlosťou liatia, chladením vo forme a postrekom chladenia v rôznych fázach, spolu s chemickým zložením, čo má vplyv na vlastnosti a kvalitu vyrábaných ocelových blokov.

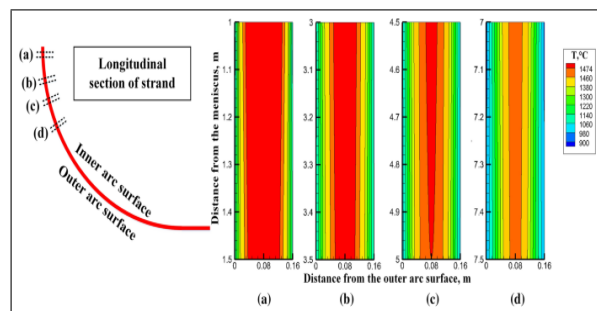


Fig. 4. Numerická simulácia štruktúry tuhnutia kontinuálne liateho predliatku. [6]

IV. APLIKÁCIE OPTIMALIZÁCIE PROCESOV V OCELIARSKOM PRIEMYSELE

A. Prvý prípad: Identifikácia optimálneho zloženia a parametrov procesu kontinuálneho odlievania ocele

V prvom testovacom prípade sa numerický model použil na generovanie súboru testovacích, trébovacích údajov pre neurónovú sieť. Celkovo bolo vygenerovaných 240 súprav odpovedajúcich hodnôt pre zvolenú kombináciu 19 vplyvných parametrov. Tieto sa skladali z parametrov chemického zloženia (koncentrácie legujúcich prvkov Cr, Cu, Mn, Mo, Ni, Si, V, C, P, S), rozmerov bloku, teploty odlievania, prehriatie odlievania, rýchlosti odlievania, teplotného rozdielu chladiacej vody vo forme, prúdu chladenia vo forme, teploty chladiacej vody v sprejoch, prúdu chladenia v korunke spreja a prúdu chladenia v prvom systéme sprejov. Na strane výstupu sa zohľadňovali metalurgická dĺžka (vid' Fig. 3, [1]), hrúbka škrupiny na konci formy a teplota povrchu bloku v mieste začiatku vyrovnávania.

V štúdii využili vzorkované údaje na trébovanie dvojvrstvovej umelej neurónovej siete s aktivačnou funkciou sigmoid. Zistilo sa, že dosiahli dostatočnú kvalitu aproximácie, čo overili tým, že z trébovacieho procesu vynechali rôzne náhodné kombinácie vzoriek a následne kontrolovali chybu aproximácie v týchto bodoch. Po ukončení

TABLE I
OPTIMALIZOVANÉ PROCESNÉ PARAMETRE.

Popis	Jednotky	Rozsah v trérovacej sade	Optimálna hodnota
1: Koncentrácia chrómu [hm. %]	0,1 - 1,15	1,0	1,05
2: Koncentrácia meď [hm. %]	0,075 - 0,175	0,1	0,125
3: Koncentrácia mangánu [hm. %]	0,375 - 1,725	0,9	0,75
4: Koncentrácia molybdénu [hm. %]	0,01 - 0,45	0,03	0,025
5: Koncentrácia niklu [hm. %]	0,075 - 0,2	0,15	0,1
6: Koncentrácia kremíka [hm. %]	0,18 - 0,6	0,3	0,275
7: Koncentrácia vanádu [hm. %]	0,025 - 0,155	0,155	0,025
8: Koncentrácia uhlíka [hm. %]	0,07 - 0,61	0,51	0,415
9: Koncentrácia fosforu [hm. %]	0,0075 - 0,0225	0,0125	0,015
10: Koncentrácia síry [hm. %]	0,01 - 0,0525	0,035	0,0275
11: Rozmery bloku [mm]	140 - 180	180	140
12: Teplota odlievania [°C]	1515 - 1562	1521	1534
13: Nadmerné ohriatie liatia [°C]	15 - 59	40	43
14: Rýchlosť odlievania [m/min]	1,03 - 1,86	1,13	1,74
15: Teplotný rozdiel chladiacej vody v forme [°C]	5 - 10	7	8,1
16: Prietok chladiacej vody v forme [l/min]	1050 - 1446	1308	1134
17: Teplota chladiacej vody v postreku [°C]	18 - 33	26	19
18: Prietok chladiacej vody v postreku [l/min]	10 - 39	10	18
19: Prietok chladiacej vody v prvom postreku [l/min]	28 - 75	31	48

TABLE II
POZOROVANÉ VÝSTUPNÉ HODNOTY PROCESU.

Popis	Rozsah v trérovacej sade	Počiatková hodnota	Cieľová hodnota	Optimálna hodnota
1: Metalurgická dĺžka [m]	8,6399 - 12,54	11,19	10,31	10,3137
2: Hrúbka plášte'a na konci formy [m]	0,0058875 - 0,0210225	0,0167	0,0124	0,01259
3: Teplota povrchu bloku na začiatku narovnávania [°C]	1064,5 - 1163,5	1114	1121	1120,3296

trénovania uložili stav siete, aby mohli aproximovať vybrané výstupné hodnoty procesu v závislosti od vstupných parametrov. Na tento aproximovaný model aplikovali optimalizačnú procedúru s cieľom dosiahnuť žiaduce správanie procesu, pokiaľ ide o metalurgickú dĺžku, hrúbku škrupiny a teplotu povrchu bloku. Problém je definovaný nasledovne [5]:

$$\min_{\mathbf{x}} \sum_{i=1}^n \left(\frac{(\mathbf{o}_i - \mathbf{o}_i^*)}{l_i} \right)^2$$

- \mathbf{x} je súbor optimalizačných parametrov, vrátane hmotnostných koncentrácií legujúcich prvkov a procesných parametrov,
- \mathbf{o}_i sú pozorované výstupné hodnoty vypočítané numerickou simuláciou procesu pri daných vstupných parametroch,
- \mathbf{o}_i^* sú príslušné cieľové hodnoty týchto veličín, a
- l_i sú príslušné škálovacie dĺžky, ktoré sa používajú na kompenzáciu rôznych magnítud pozorovaných veličín a na váženie ich dôležitosti.

Škálovacie dĺžky sa zvyčajne určujú ako dĺžky intervalov akceptovateľných hodnôt príslušných veličín.

Výsledky sú uvedené v Tabuľke 1. Tento prvý príklad je akademický, keďže chemické zloženie ocele zvyčajne určuje zákazník. Používa sa na demonštráciu schopnosti našej metodológie zvládať viac procesných parametrov a identifikovať prospešné zmeny v chemickom zložení v niektorých prípadoch. Na dosiahnutie tohto cieľa bola použitá globálna-lokálna metóda. V prvom štádiu naši približne optimálnu sadu parametrov preskúmaním

všetkých dátových bodov a výberom bodu s najmenšou hodnotou minimalizovanej funkcie ako počiatkového odhadu v druhom štádiu (uvedeného v Tabuľke 1 ako počiatkový odhad). Následne vykonali detailnú optimalizáciu pomocou modifikovaného algoritmu Nelder-Mead [7].

B. Druhý prípad: Optimalizácia procesných parametrov pri kontinuálnom liati ocele

Druhý príklad je zameraný na optimalizáciu procesných parametrov pri ustálenom chemickom zložení ocele. Kritériá optimalizácie a obmedzenia sú stanovené s cieľom maximalizovať produktivitu a zároveň udržať množstvo defektov vo vyrábaných blokoch v akceptovateľnom rozsahu. Problém bol riešený pre ocelovú triedu CrV4 s nasledujúcim chemickým zložením: 1,03% Cr, 0,205% Cu, 0,875% Mn, 0,045% Mo, 0,145% Ni, 0,3% Si, 0,14% V, 0,515% C, 0,014% P, 0,01% S, pričom hmotnostné frakcie prvkov sú špecifikované v hmotnostných percentách. Pri optimalizácii sa zohľadňovalo päť parametrov: teplota odlievania T_c , rýchlosť odlievania v , rozdiel medzi vstupnou a výstupnou teplotou chladiacej vody vo forme ΔT , prietok v systéme sprejového chladenia Q_w (umiestnenom ihneď po forme) a prietok v prvom systéme sprejového chladenia Q_1 : $x = \{\Delta T, v, T_c, Q_w, Q_1\}$.

Bola vygenerovaná sada 10 000 trérovacích vstupno-výstupných dvojíc spustením numerického simulátora s náhodne zvolenými parametrami v stanovenom rozsahu parametrov. Rozsahy parametrov boli upravené podľa obmedzení procesu odlievanej formy "limitation of the

caster". Pre každú sadu parametrov bol vypočítaný a uložený súbor troch výstupných hodnôt na neskoršie použitie pri tréňovaní modelu ANN: metalurgická dĺžka l_m , hrúbka tuhnutého plášťa na konci formy d_s a teplota povrchu bloku v mieste začiatku rovnania, T_s . Optimalizačný problém bol definovaný nasledovne:

$$\begin{aligned} & \min(-k_1 \cdot T + k_2 \cdot (d_{d,used} - d_{l,used}) + k_3 \cdot (l_{l,used} - l_{d,used})) \\ & \text{subject to:} \\ & d_{\min} < d < d_{\text{upper}} \\ & T < T_{\max} \\ & l_{\text{lower}} < l < l_{\text{upper}} \end{aligned} \quad (1)$$

Kde:

$$\begin{aligned} d_{\text{upper}} &= 11 \text{ mm}, d_{l,used} = 14 \text{ mm}, d_{d,used} = 12 \text{ mm} \\ T_{\max} &= 1100^\circ \text{C} \\ l_{\text{lower}} &= 9 \text{ mJ}, l_{\text{upper}} = 11 \text{ mJ}, l_{used} = 9 \end{aligned} \quad (2)$$

Definícia problému sa snaží optimalizovať produkčnú rýchlosť odlievanej formy, ktorá je úmerná rýchlosti liatia v , a zohľadňuje odborné znalosti o rozsahoch výstupných veličín, ktoré zabezpečujú bezproblémový proces s minimom defektov [8]. Hrúbka plášťa na konci formy je obmedzená, aby poskytla potrebnú mechanickú podporu roztavenému kovu, a teplota povrchu bloku by nemala byť príliš nízka, aby sa predišlo problémom pri ohýbaní bloku. Metalurgická dĺžka je obmedzená zhora dĺžkou od formy k miestu začiatku narovnávania, kde by mal byť blok úplne tuhý. Obmedzuje sa aj zdola, aby sa predišlo problémom pri ohýbaní bloku v prípade, že by bol úplne tuhý pred miestom začiatku narovnávania. Pre dostatočnú formovateľnosť po odliati je žiaduce, aby bola teplota povrchu vyššia na začiatku narovnávania, pričom existuje známa dolná hranica, nad ktorou by mala byť udržiavaná teplota povrchu. Optimum bolo dosiahnuté pri $T_c = 1516^\circ \text{C}$, $v = 1.793 \text{ m/min}$, $\Delta T = 7.35^\circ \text{C}$, $Q_w = 21.4 \text{ l/min}$ a $Q_1 = 43.7 \text{ l/min}$.

TABLE III

VÝSLEDKY OPTIMALIZOVANÝCH PARAMETROV ODLIEVANIA.

Popis a jednotky	Počiatková hodnota	Optimálna hodnota
Metalurgická dĺžka [m]	10.25	10.95
Hrúbka škrupiny na konci formy [m]	0.0115	0.01325
Teplota bilietu pri začiatku rovnania [$^\circ\text{C}$]	1112.4	1156
Rýchlosť odlievania [m/min]	1.54	1.793

C. Použité neurónové siete

V oboch príkladoch optimalizácie sa použili dopredné umelej neurónovej siete s algoritmom spätného šírenia chyby na vytvorenie modelov. Boli vyskúšané rôzne kombinácie rozložení a tréňovacích parametrov, ktoré boli zvolené na základe minulých skúseností [9], [10] a ďalšieho experimentovania. Bolo vykonaných viac ako 20 tréňovaní, pričom boli vyskúšané rôzne parametre. Dobré výsledky

boli dosiahnuté použitím ANN s jednou skrytou vrstvou obsahujúcou 20-40 neurónov. Miera učenia, ktorá určuje rýchlosť učenia, bola nastavená na 0,3. Momentum, ktorý určuje, koľko predchádzajúcej korekčnej termínu sa má aplikovať pri súčasnom tréňovaní, bol nastavený na 0,6.

V. ZÁVER

V tomto prehľadovom článku sme zhodnotili význam aplikácie umelej neurónovej siete na optimalizáciu procesných parametrov pri kontinuálnej liatine ocele. Na základe analýzy existujúcich štúdií sme identifikovali potenciálne výhody a prínosy tejto metódy pre oceliarsky priemysel. Umele neurónové siete môžu byť využité na optimalizáciu procesov, predikciu vlastností materiálu a rýchle a efektívne spracovanie veľkého množstva údajov. Diskutovali sme o možnostiach ďalšieho výskumu a využitia neurónových sietí na optimalizáciu výrobných procesov ocele s cieľom dosiahnuť efektívnejšiu výrobu a zlepšiť kvalitu výsledných produktov.

Napriek týmto výhodám je dôležité zvážiť aj niektoré nevýhody použitia neurónových sietí, ako je potreba veľkého množstva dát pre tréňovanie, ich zložitosť a citlivosť na šum v dátach. Budúce štúdie by sa mali zamerať na rozšírenie aplikácií neurónových sietí v oceliarskom odvetví a na ďalšie zdokonaľovanie optimalizačných postupov s cieľom dosiahnuť ešte lepšie výsledky a efektívnosť výrobných procesov. Tento prehľad naznačuje dôležitosť a perspektívu aplikácie umelej inteligencie v oceliarskom odvetví a podnecuje ďalší výskum v tejto oblasti.

REFERENCES

- [1] R. Vertnik, "Heat and fluid flow simulation of the continuous casting of steel by a meshless method," Ph.D. dissertation, University of Nova Gorica, 2010.
- [2] I. Grešovnik, T. Kodolja, R. Vertnik, and B. Šarler, "A software framework for optimization of process parameters in material production," *Applied Mechanics and Materials*, vol. 101-102, pp. 838-841, 2012.
- [3] I. Grešovnik, "The use of moving least squares for a smooth approximation of sampled data," *Strojnicki vestnik - Journal of Mechanical Engineering*, vol. 53, no. 9, pp. 582-598, 2007. [Online]. Available: <https://www.sv-jme.eu/article/the-use-of-moving-least-squares-for-a-smooth-approximation-of-sampled-data/>
- [4] R. Rojas, *Neural Networks—A Systematic Introduction*. Berlin: Springer-Verlag, 1996.
- [5] I. Grešovnik, T. Kodolja, R. Vertnik, and B. Šarler, "Application of artificial neural networks to improve steel production process," in *Proceedings of the IASTED International Conference on Artificial Intelligence and Soft Computing*, ASC, vol. 2012, 2012.
- [6] Z. Wang, S. Luo, W. Wang, and M. Zhu, "Numerical simulation of solidification structure of continuously cast billet with grain motion," *Metallurgical and Materials Transactions B*, vol. 51, no. 6, pp. 2882-2894, 2020. [Online]. Available: <https://doi.org/10.1007/s11663-020-01953-2>
- [7] I. Grešovnik, "Simplex algorithms for nonlinear constrained optimization problems," Technical report, Tech. Rep., 2009. [Online]. Available: <http://www2.arnes.si/~ljc3m2/igor/doc/rep/optalgsimplex.pdf>
- [8] W. Bennon and F. Incropera, "A continuum model for momentum, heat and species transport in binary solid-liquid phase change systems—I. model formulation," *International Journal of Heat and Mass Transfer*, vol. 30, no. 10, pp. 2161-2170, 1987. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/0017931087900949>

- [9] M. Abel, A. Carley, J. Watts, I. Belič, B. Poniku, and M. Jenko, "Neural network for aes spectra peak base background removal," *Surface and Interface Analysis*, vol. 44, 08 2012.
- [10] L. Belič, I. Belič, B. Erjavec, and J. Setina, "Neural network modelling of cold-cathode gauge parameters," *Vacuum*, vol. 71, 07 2003.