

# Predpovedanie veľkosti rozsevu aglomerátu pomocou CNN modelu

Tatiana Čarnická

Technická univerzita v Košiciach  
Fakulta elektrotechniky a informatiky  
Košice, Slovensko  
tatiana.carnicka@student.tuke.sk

**Abstract**—Tento dokument sa zameriava na využitie konvolučnej neurónovej siete (CNN) na predikciu veľkosti rozsevu aglomerátu v oceliarskom priemysle. Použitie CNN modelu na predikciu rozsevu aglomerátu má potenciál priniesť značné benefity v oceliarskom priemysle. Optimalizáciou procesu výroby aglomerátu na základe prediktívnych modelov je možné znížiť náklady a zároveň zlepšiť kvalitu produktu.

**Index Terms**—prediction, CNN, steel industry, neural network

## I. ÚVOD

V dnešnom svete sa primárne sústreďujeme na zdokonalenie výrobných procesov, zmenšenie nákladov a celkovú optimalizáciu výrobných procesov. Jedným z kritických procesov v oceliarskom odvetví je výroba aglomerátu. Kľúčovým zložkou kvalitného aglomerátu je dobrý rozsev.

V tomto dokumente budeme skúmať CNN model a jeho schopnosť predpovedania číselných údajov, pomocou ktorej sa budeme snažiť predpovedať veľkosť rozsevu.

## II. VSTUPNÉ DÁTA

Naše dáta obsahujú údaje pochádzajúce zo senzorov na spekacom páse a zaznamenávajú hodnoty rozsevu v rozmedzí 0-5 milimetrov každú pol hodinu po celý rok. Hodnota rozsevu slúži ako kľúčový indikátor kvality produktu: nízke hodnoty pod 12 mm značia dobrú kvalitu, zatiaľ čo prekročenie tejto hranice môže naznačovať zhoršenie kvality a problémy vo výrobe. Dáta sú nenahradiateľné pre monitorovanie, riadenie a predpovedanie výrobných procesov a ich správne spracovanie nám môže pomôcť optimalizovať výrobný proces.

### A. Predspracovanie

Po načítaní pôvodných dát zo súboru pomocou knižnice pandas, boli upravené časy meraní, kde sa prechádzalo cez všetky pôvodné dátumy a časy meraní, ktoré boli zaokrúhľované na najbližší interval. Zaokrúhľované boli buď na 11:00 alebo na 23:00, pretože v daných časoch sa oficiálne vykonávajú merania rozsevu. Takto zaokrúhlené časy boli potom uložené do nového zoznamu.

Potom sa pre každý nájdený najbližší čas vyfiltrovali príslušné riadky z pôvodných dát a tieto dáta boli spracované

a priradené k odpovedajúcim časovým intervalom z druhého dokumentu obsahujúceho údaje o meraniach.

Následne sa našli zhodné dátumy medzi týmito súbormi dát a pre tieto dátumy sa vytvoril výstupný súbor, ktorý obsahoval zhodné dátumy a príslušné údaje k týmto dátumom. Z výsledného súboru boli nakoniec odstránené nepotrebné stĺpce a duplikáty a boli vytvorené nové stĺpce v závislosti na našich potrebách. Nakoniec boli výsledné dáta uložené do nového súboru, čím sme vytvorili čistý a prehľadný výstup.

### B. Analýza dát

Dáta po úpravách obsahovali 2889 záznamov a 19 atribútov. Z pôvodných dokumentov sme ponechali atribúty, ktoré hrajú kľúčovú úlohu pri tvorbe aglomerátu. Patria medzi ne napríklad: prietok koksu, celkový prietok paliva, skutočný prietok vody do miešacieho bubna, vlhkosť zmesi a podtlak, ktorý reguluje palič.

Analýza výstupných hodnôt, teda rozsevu, ukazuje koncentráciu hodnôt okolo priemeru (10) s výskytom extrémnych hodnôt (do 50) ovplyvnených špecifickými podmienkami. Presná charakteristika dát a overenie ich relevancie sú dôležité pre ich efektívne využitie. Je dôležité poznamenať, že dáta sú rozložené v pomerne rovnomerných intervaloch, čo naznačuje systematické a konzistentné merania.

## III. KONVOLUČNÉ NEURÓNOVÉ SIETE (CNN)

Konvolučné neurónové siete (CNN) predstavujú široko používaný typ neurónových sietí v oblasti počítačového videnia, kde excelujú vo spracovaní obrázkových dát. Avšak ich aplikácia sa neobmedzuje len na túto oblasť. V tomto článku sa zameriame na použitie CNN na predikciu veľkosti rozsevu aglomerátu.

### A. Čo je to CNN?

Konvolučné neurónové siete (CNN) sú typ neurónových sietí, ktoré sa vyznačujú tým, že sú schopné efektívne pracovať s dátami s topologickou štruktúrou, ako sú obrázky, časové rady, či texty. Ich architektúra sa zameriava na zachytenie hierarchie príznakov v dátach pomocou konvolučných vrstiev, združovacích vrstiev a plne prepojených vrstiev [2].

CNN využívajú špeciálne vrstvy nazývané konvolučné vrstvy, ktoré obsahujú sady filtrov (jadrá), ktoré sa aplikujú na vstupné dáta pomocou operácie konvolúcie. Tieto filtre prechádzajú cez vstupné dáta a extrahujú rôzne príznaky, ako sú hrany, textúry a ďalšie relevantné informácie. Tieto príznaky sú následne združené pomocou vrstiev združovania (pooling), čo pomáha znížiť dimenziu dát a zachovať ich invariantné vlastnosti voči posunu a zmene mierky [1].

Hoci boli CNN pôvodne navrhnuté na klasifikáciu obrázkových dát, ich aplikácia sa rozšírila aj na regresné úlohy, vrátane predikcie číselných hodnôt. Pri predikcii číselných hodnôt CNN fungujú podobne ako pri klasifikácii, avšak namiesto výstupnej vrstvy s viacerými triedami máme jednu výstupnú vrstvu s jedným neurónom, ktorý vracia spojitý výstup.

## B. Výhody vs. Nevýhody

### Výhody:

- 1) Schopnosť zachytávať vzory vo vizuálnych dátach: CNN sú špeciálne navrhnuté na prácu s vizuálnymi dátami, ako sú obrázky a videá. Ich architektúra je optimalizovaná na efektívnu extrakciu príznakov z týchto dát, čo z nich robí vynikajúci nástroj pre problémy v oblasti počítačového videnia.
- 2) Hierarchická extrakcia príznakov: CNN majú schopnosť hierarchicky extrahovať príznaky zo vstupných dát. To znamená, že môžu identifikovať jednoduchšie vzory a postupne ich kombinovať do zložitejších príznakov, čo umožňuje učiť sa zložitý vzťahy v dátach.
- 3) Časová a priestorová lokalita: Pri práci s obrázkami a inými dátami, ktoré majú priestorovú štruktúru, sú CNN schopné zachytiť lokálne vzory a vzťahy medzi susednými prvkami dát, čo je dôležité pre ich správne spracovanie.
- 4) Regularizácia: Vďaka využitiu vrstiev ako Dropout a Batch Normalization majú CNN zabudovanú schopnosť regularizácie, čo pomáha predchádzať pretrénovaniu a zlepšuje ich výkon na testovacích dátach.
- 5) Paralelné spracovanie: Konvolučné vrstvy v CNN sú navrhnuté tak, aby boli efektívne paralelizovateľné, čo umožňuje ich rýchle tréningy a predikciu na moderných grafických kartách (GPU).

### Nevýhody:

- 1) Náročnosť na dáta: Aj keď CNN majú schopnosť extrahovať príznaky z dát, vyžadujú veľké množstvo tréningových dát pre dosiahnutie dobrých výsledkov. Pre niektoré aplikácie môže byť ťažké získať dostatočné množstvo kvalitných dát.
- 2) Náročnosť na výpočtový výkon: Tréning hlbokých CNN môže byť veľmi výpočtovo náročný, najmä ak sa pracuje s veľkými množstvami dát a hlbokými architektúrami s veľkým počtom parametrov.
- 3) Interpretovateľnosť: Kvôli ich zložitej architektúre a hierarchickej extrakcii príznakov môže byť interpretácia

rozhodnutí CNN obtiažnejšia v porovnaní s inými modelmi, ako sú napríklad rozhodovacie stromy.

- 4) Potreba ošetrovania hyperparametrov: Optimalizácia výkonnosti CNN môže byť náročná vzhľadom na veľké množstvo hyperparametrov, ktoré treba nastaviť, ako sú veľkosť jadier, počet vrstiev, veľkosť dávky (batch size) atď.
- 5) Náchylnosť na pretrénovanie: Hlboké CNN majú tendenciu sa ľahko pretrénovať na tréningové dáta, čo môže viesť k horším výsledkom na nových, nevidených dátach, ak nie sú vhodne regularizované[4].

## C. Popis siete

Pre našu úlohu predikcie veľkosti rozsevu aglomerátu sme zvolili nasledovnú architektúru siete:

- Konvolučné vrstvy: Použili sme tri konvolučné vrstvy s postupne klesajúcim počtom filtrov (128, 64, 32). Každá konvolučná vrstva má jadro (kernel) veľkosti 3, čo znamená, že každý filter prechádza cez tri po sebe idúce prvky vstupného signálu.
- Normalizačné vrstvy: Za každou konvolučnou vrstvou sme pridali vrstvu normalizácie (Batch Normalization), čo pomáha stabilizovať a urýchliť učenie modelu tým, že normalizuje aktivačné hodnoty medzi vrstvami.
- Aktivačné funkcie: Na aktiváciu konvolučných vrstiev sme použili LeakyReLU, ktorá rýchlo konverguje k nule pre záporné hodnoty a je nelineárna, čo umožňuje sieti naučiť sa zložitý vzory v dátach [3].
- Vrstvy združovania (pooling): Po každej konvolučnej vrstve nasleduje vrstva združovania typu Max Pooling, ktorá redukuje rozmery výstupu konvolučných vrstiev a tým znižuje výpočtovú náročnosť a zabraňuje pretrénovaniu siete.
- Plne prepojené vrstvy: Na konci siete sme pridali plne prepojené vrstvy, ktoré prijímajú vstup z lineárneho vektora získaného z predchádzajúcich vrstiev a vykonávajú záverečné klasifikačné rozhodnutia. V našom prípade sme použili dve plne prepojené vrstvy s aktivačnou funkciou LeakyReLU a jednu výstupnú vrstvu bez aktivačnej funkcie.

Toto nastavenie bolo zvolené na základe experimentov s architektúrou siete a ich vyhodnotením na validačnej sade.

## D. Prečo sme si zvolili danú sieť?

Pre našu úlohu predikcie veľkosti rozsevu aglomerátu sme sa rozhodli použiť CNN kvôli jej schopnosti efektívne pracovať s časovými radmi a zachytávať vzory v sekvenciálnych dátach. Konvolučné vrstvy sú schopné detekovať priestorové vzory vstupných dát, čo je v prípade našej úlohy dôležité, pretože veľkosť rozsevu aglomerátu môže byť ovplyvnená rôznymi faktormi v procese výroby.

## IV. VÝSTUP

### A. Evaluácia siete

Pri tréningu a validácii siete používame metriku Mean Squared Error (MSE) ako stratovú funkciu. Táto metrika

vyjadruje priemernú kvadratickú chybu medzi predikciami a skutočnými hodnotami. Model dosahuje počas tréovania a validácie v priebehu 300 epoch postupne klesajúce hodnoty straty, čo naznačuje, že sa sieť učí a prispôbuje sa lepšiemu zosúladieniu predikcií so skutočnými hodnotami.

Presnosť (Accuracy) modelu je 73.79% takže je pomerne vysoká, čo naznačuje, že model správne predikuje veľkosti rozsevu aglomerátu vo väčšine prípadov, ako môžeme vidieť na obrázku Fig. 1.




Fig. 1. Skutočné vs. Predpovedané hodnoty rozsevu

Priemerná absolútna chyba (Mean Absolute Error) vyjadruje priemernú absolútnu odchýlku medzi predikovanými a skutočnými hodnotami. V tomto prípade sme dostali hodnotu 0.916, čo znamená, že tento model sa priemerne mýli o približne 0.916 jednotky, čo je relatívne nízka hodnota.

Priemerná kvadratická chyba (Mean Squared Error) vyjadruje priemernú kvadratickú odchýlku medzi predikovanými a skutočnými hodnotami. Model dosahuje MSE približne 2.640, čo znamená, že priemerná kvadratická odchýlka je relatívne nízka.

Celkovo vzaté, používaný model dosahuje pomerne dobré výsledky, s vysokou presnosťou a nízkymi hodnotami chýb, ako môžeme vidieť na obrázku Fig. 2, no v budúcnosti by sa dal ešte vylepšiť.




Fig. 2. Porovnanie chýb

## REFERENCES

- [1] O'SHEA, Keiron; NASH, Ryan. An introduction to convolutional neural networks. arXiv preprint arXiv:1511.08458, 2015.
- [2] ALBAWI, Saad; MOHAMMED, Tareq Abed; AL-ZAWI, Saad. Understanding of a convolutional neural network. In: 2017 international conference on engineering and technology (ICET). Ieee, 2017. p. 1-6.
- [3] NWANKPA, Chigozie, et al. Activation functions: Comparison of trends in practice and research for deep learning. arXiv preprint arXiv:1811.03378, 2018.
- [4] ALZUBAIDI, Laith, et al. Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. Journal of big Data, 2021, 8: 1-74.