

Umelá inteligencia v oceliarskom priemysle

Tatiana Čarnická
Technická Univerzita v Košiciach
Fakulta elektrotechniky a informatiky

Abstract—Oceliarsky priemysel je dôležitou súčasťou globálnej ekonomiky a jeho úspešné fungovanie je nevyhnutné pre mnohé odvetvia. S nárastom dopytu po oceli a narastajúcimi požiadavkami na efektívnosť a kvalitu výroby sa stáva nevyhnutným využitie moderných technológií, ako je umelá inteligencia (AI). Tento článok prezentuje široké spektrum aplikácií umelej inteligencie v oceliarskom priemysle a analyzuje výhody, nevýhody a výzvy spojené s ich implementáciou. Ďalej sa zaoberá skúmanými metódami strojového učenia, ako sú lineárna regresia, umelé neurónové siete, Support Vector Regression, Random Forest a Multivariate Adaptive Regression Splines, a diskutuje o ich výkonnosti a vhodnosti pre rôzne úlohy v oceliarskom priemysle. Článok tiež poskytuje prehľad vývoja modelu umelej neurónovej siete (ANN) a krokov, ktoré je potrebné pri jeho vytváraní.

Index Terms—Výroba ocele, Umelá inteligencia, Neurónové siete

I. OCEĽ

A. Oceliarsky priemysel

Industrializácia a urbanizácia vo svete podporili dopyt po oceli počas posledných dvoch desaťročí. Spoločné odhady toho, koľko ocele je potrebné pre vysoký hospodársky rozvoj, sú nevyhnutné pre lepšie porozumenie budúcich výziev v oblasti zamestnanosti, riadenia zdrojov, plánovania kapacít a zmiernenia klimatických zmien v oceľovom sektore. Na obrázku 'Fig 1.' vidíme, ako sa zásoby ocele časom vyvíjajú po aplikovaní dynamickej analýzy materiálových tokov na odhadovanie používaných zásob ocele v približne 200 krajinách [3].

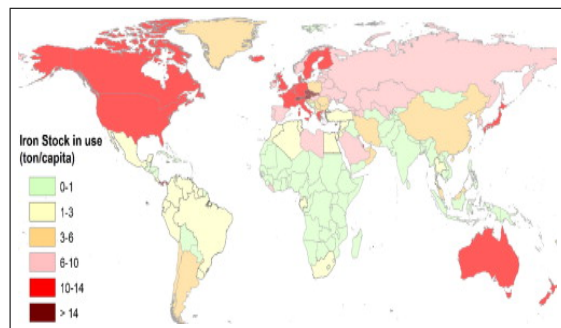


Fig. 1. Rozloženie využívaných zásob ocele na obyvateľa vo svete [3]

Celková svetová produkcia ocele prekročila v roku 2005 hranicu jednej miliardy ton a očakáva sa jej ďalší nárast. V západných krajinách tvorí podiel ocele vyrobenej pre-tavením recyklovaného oceľového šrotu v elektrických

oblúkových peciach takmer polovicu ich celkovej produkcie ocele [2].

B. Proces výroby ocele

Proces výroby ocele je zložitý a zahŕňa niekoľko kľúčových krokov, ktoré sú nevyhnutné na dosiahnutie konečného produktu s požadovanými vlastnosťami.

Prvým krokom je príprava surovín, ktorá zahŕňa železnú rudu, vápenný kameň a koksovacie uhlie. Tieto suroviny sú základom celého procesu a ich kvalita má významný vplyv na kvalitu výslednej ocele.

Ďalším dôležitým krokom je koksovanie, proces, pri ktorom je uhoľný materiál (koksovacie uhlie) vystavený vysokým teplotám bez prítomnosti vzduchu. Výsledkom tohto procesu je vytvorenie koksu, ktorý je nevyhnutnou surovinou pre výrobu ocele.

Po pripravení surového materiálu nasleduje tavba a redukcia železnej rudy na surové železo. Toto surové železo je potom ďalej spracované v konvertoroch, kde sa pre-mieňa na oceľ. Proces konvertorovania zahŕňa odstraňovanie nečistôt a úpravu zloženia kovu podľa požiadaviek na konkrétny výrobok.

Po konvertorovom procese nasleduje tvarovanie a formovanie ocele do požadovaných tvarov a foriem. To sa dosahuje pomocou rôznych techník, ako je odlievanie, kovanie alebo valcovanie. Každá z týchto techník má svoje vlastné výhody a je vhodná pre rôzne typy výrobkov.

Po formovaní sa oceľ chladí a spracováva tak, aby dosiahla požadované mechanické vlastnosti. Tento proces môže zahŕňať tepelné spracovanie, tvrdnutie alebo ďalšie úpravy, ktoré zlepšujú pevnosť a odolnosť materiálu.

Následne je výsledný produkt podrobený testovaniu a kontrole kvality, aby sa zabezpečilo, že spĺňa stanovené normy a požiadavky zákazníka. Testovanie môže zahŕňať skúšky pevnosti, testy na deformáciu a ďalšie kontrolné postupy. Nakoniec je finálny produkt expedovaný z výrobného zariadenia a buď použitý priamo, alebo ďalej spracovaný v ďalších procesoch.

Celý proces výroby ocele je dôkladne plánovaný a riadený, aby sa zabezpečila vysoká kvalita a spoľahlivosť výsledného produktu, ktorý je nevyhnutný pre mnoho odvetví priemyslu a koncových aplikácií [1].

II. UMEĽÁ INTELIGENCIA V OCELIARSTVE

Umelá inteligencia (AI) má v oceliarskom priemysle široké spektrum aplikácií a môže priniesť mnoho benefitov. Zároveň však implementácia AI čelí aj rôznym výzvam a obmedzeniam [5].

V oceliarskom priemysle prináša umelá inteligencia (AI) rad výhod, ktoré ovplyvňujú nielen efektívnosť, ale aj konkurencieschopnosť tohto odvetvia. Jednou z hlavných výhod je schopnosť riešiť nedostatok kvalifikovaných pracovníkov. AI dokáže nahradiť skúsených expertov v oceliarskych prevádzkach, čím sa prekonávajú problémy spojené s ich starnutím a ubúdaním.

Okrem toho, AI prináša systematický prístup a kontrolu do oceliarskych procesov. Stáva sa štandardom pre systematizáciu a riadiace procesy, čo výrazne zefektívňuje a stabilizuje výrobu. Ďalšou výhodou je efektívne riešenie problémov, kde AI technológie, najmä expertné systémy, poskytujú podporu pri diagnostike zariadení, riešení problémov a plánovaní výrobných procesov.

AI sa v oceliarskom priemysle uplatňuje vo viacerých oblastiach, vrátane výroby železa, povlakovania, plánovania, kontroly dopravy a diagnostiky zariadení. Dôležitou výhodou je aj rozmanitosť technológií, ktoré AI ponúka na riešenie rôznych výziev, ako sú expertné systémy, fuzzy logika, neurónové siete a genetické algoritmy. Relatívne vysoká úspešnosť AI systémov prispieva k ich atraktivite, aj keď sa táto miera môže líšiť v závislosti od konkrétneho použitia.

Napriek týmto výhodám však implementácia AI v oceliarskom priemysle čelí určitým výzvam a obmedzeniam. Medzi tieto patrí ťažkosť s náborom kvalifikovaných pracovníkov s potrebnými zručnosťami v oblasti AI technológií. Ďalším obmedzením je zložitosť expertných systémov a variabilita ich úspešnosti v závislosti od kritérií hodnotenia. Dôležitá je aj fáza praktickej aplikácie, kde je potrebné zhodnotiť skutočný prínos AI technológií a ich účinnosť.

Napriek týmto výzvam existujú príklady úspešných implementácií AI v oceliarskom priemysle. Patria sem diagnostika hydraulických a rotačných strojov, riešenie problémov s elektrickými zariadeniami, plánovanie distribúcie a kontrola, ako aj prideľovanie lodí.

Trendy v používaní AI technológií v oceliarskom priemysle smerujú k rýchlemu zavádzaniu AI do výrobných procesov a zvýšenému dôrazu na praktické využitie AI ako štandardnej techniky. Rastie aj záujem o transfer expertízy v oblasti kvalifikovaných prác s využitím AI.

Celkovo má umelá inteligencia veľký potenciál v oceliarskom priemysle, ale úspešná implementácia si vyžaduje prekonanie rôznych výziev a neustále sústredovanie sa na praktické využitie v súlade s potrebami tohto odvetvia.

Výroba ocele je komplexným odvetvím, kde každý jednotlivý proces v reťazi výroby generuje obrovské množstvo údajov, ktoré môžu poskytnúť cenné poznatky. Medzi niektoré z technológií umelej inteligencie, ktoré sa používajú v procesoch výroby ocele patria napríklad tieto [4]:

- **Strojové učenie:** Algoritmy strojového učenia sa používajú na analýzu dát, identifikáciu vzorov a predikciu v rôznych aspektoch výroby ocele, ako je kontrola kvality, optimalizácia procesov a detekcia anomálií [4].

- **Hlboké učenie:** Techniky hlbokého učenia, ktoré sú podmnožinou strojového učenia, sa využívajú na úlohy ako klasifikácia časových radov na predikciu výsledkov, množstvo odpadu a kvalita produktov v procesoch výroby ocele [4].
- **Multi-agentové systémy:** Na plánovanie výroby a riadenie v oceliarskom priemysle sa využívajú AI založené multi-agentové systémy, ktoré umožňujú spoluprácu pri rozhodovaní a koordináciu medzi rôznymi entitami v rámci výrobného procesu [4].
- **Detekcia anomálií:** Technológie umelej inteligencie sa používajú na detekciu anomálií v procesoch, ako je tvrdé prelisovanie v oceliarskej výrobe, aby sa zabezpečila kvalita výrobku a účinnosť procesu [4].

	Strengths	Weaknesses
Expert Systems	<ol style="list-style-type: none"> 1. Expansion of the range of objects of systemization 2. Improvement of the visibility of functions expressed by software (Description is close to natural language.) 3. Improvement of software productivity 	<ol style="list-style-type: none"> 1. Poor in software maintainability (Logic is difficult to understand, tools are hard to use.) 2. Difficulty of describing very deep knowledge and large scale knowledge 3. Heavy consumption of resources, and poor response (particularly in real time control problems) 4. Development methods not mature.
Fuzzy logic	<ol style="list-style-type: none"> 1. Logic is qualitative and easily understood, and descriptions are easy. 2. Consumption of resources is low, and response is good. Suitable for control problems. 3. Expands the objects of automatic control 	<ol style="list-style-type: none"> 1. Logical support is weak. 2. Development and tuning methods have not been established. 3. Evaluation of optimumness is difficult.
Neural Networks	<ol style="list-style-type: none"> 1. Models and rules are not necessary, and construction is easy. 	<ol style="list-style-type: none"> 1. Content is a "black box." 2. Design methods are unclear. 3. Evaluation of models is difficult.
Common Points	<ol style="list-style-type: none"> 1. The availability of these methods has clearly increased the number of options which can be applied when problems must be solved. 	<ol style="list-style-type: none"> 1. Mature development methodologies do not exist for any of these techniques. 2. Theoretical support is weak, and evaluation is difficult.

Fig. 2. Silné a slabé stránky rôznych AI techník [5].

III. SKÚMANÉ METÓDY

A. Lineárna regresia

Formuluje hypotézu a funkciu nákladov na základe vstupných premenných. Používa analytickú metódu na minimalizovanie funkcie nákladov a nájdenie regresných koeficientov. Vyhodnocuje výkonnosť pomocou RMSE a korelačného koeficientu.

Výhody:

- Lineárna regresia je jednoduchá a ľahko interpretovateľná, vďaka čomu je dobrým východiskovým bodom pre prediktívne modelovanie.
- Poskytuje pohľad na vzťahy medzi premennými a môže sa použiť na vytváranie predpovedí na základe týchto vzťahov.

Nevýhody:

- Lineárna regresia predpokladá lineárny vzťah medzi nezávislými a závislými premennými, čo nemusí vždy platiť v scenároch reálneho sveta.
- Je citlivá na odľahlé hodnoty a môže byť nimi ovplyvnená, čo ovplyvňuje presnosť a spoľahlivosť modelu. [7]

B. Umelá neurónová sieť (ANN)

Normalizuje vstupné premenné pomocou min-max normalizácie. Používa štruktúru feed-forward siete s tréningovým algoritmom spätného šírenia. Ako aktivačnú funkciu volí hyperbolickú tangenciálnu sigmoidnú funkciu.

Výhody:

- ANN môže modelovať zložité vzťahy medzi vstupmi a výstupmi vďaka ich nelineárnej povahe.
- Môžu sa prispôbiť meniacim sa vstupným údajom a učiť sa z nových informácií, vďaka čomu sú univerzálne pre rôzne aplikácie.

Nevýhody:

- Vnútročné fungovanie nie je ľahko interpretovateľné.
- Trénovanie veľkých modelov ANN môže byť výpočtovo náročné a časovo náročné [6][7].

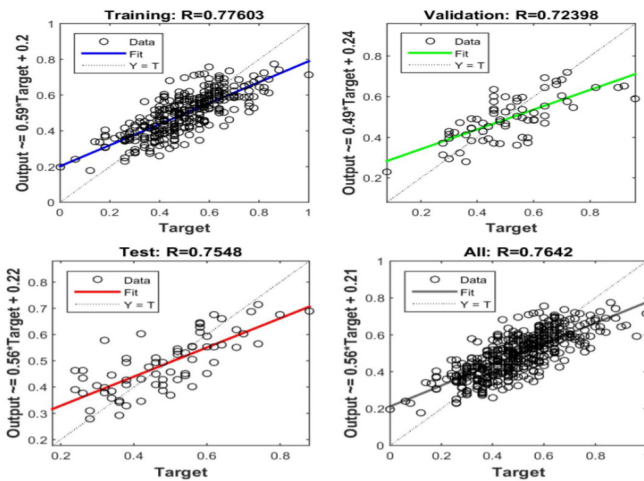


Fig. 3. Výkonnosť modelu ANN [7].

C. Support Vector Regression (SVR)

Je to algoritmus strojového učenia na regresné úlohy. Hľadá hyperplán, ktorý najlepšie vyhovuje dátovým bodom pri maximalizácii rozpätia. Zameriava sa na minimalizáciu chýb a umožňuje určitú toleranciu riadenú parametrom epsilon. Vďaka použitiu podporných vektorov dokáže SVR spracovať nelineárne dáta mapovaním do priestoru s vyššou dimenziou. SVR je účinný pre súbory dát so zložitými vzťahmi vďaka svojej robustnosti.

Výhody:

- Je efektívny v mnohorozmerných priestoroch a je pamäťovo efektívny.
- Funguje dobre so súbormi údajov, ktoré sú ľahko oddeliteľné.

Nevýhody:

- SVR môže byť citlivý na výber parametrov.
- Môže mať dlhý tréningový čas. [7]

D. Random Forest (RF)

Je to metóda, ktorá počas tréningu vytvára viaceré rozhodovacie stromy a pre regresné úlohy vytvára priemernú predpoveď jednotlivých stromov. Znižuje preučenie priemerovaním viacerých rozhodovacích stromov a šum v dátach. Zvládne veľké súbory dát s vysokou dimenzionalitou a menej pravdepodobne ovplyvnia jednotlivé stromy. Výkonnosť sa hodnotí pomocou metriík ako Mean Squared Error (MSE), Root Mean Squared Error (RMSE) a R-squared na posúdenie presnosti a predikčnej sily modelu.

Výhody:

- Random Forest je známy svojou vysokou presnosťou pri predpovedaní výsledkov.
- Je všestranný, ľahko implementovateľný a v porovnaní s inými komplexnými modelmi vyžaduje minimálne ladenie hyperparametrov.
- Dokáže spracovať veľké množiny údajov s väčším počtom dimenzií.

Nevýhody:

- Pre veľké súbory dát môže byť výpočtovo náročná a nemusí fungovať dobre na dátach s vysokým šumom a s vysokou koreláciou medzi prvkami.
- Trénovanie modelu Random Forest môže trvať dlhšie kvôli budovaniu viacerých rozhodovacích stromov.
- Ťažšia interpretovateľnosť výsledkov v porovnaní s jednoduchšími modelmi, ako je lineárna regresia. [7]

E. Multivariate Adaptive Regression Splines (MARS)

Flexibilná neparametrická regresná technika, ktorá dokáže zachytiť komplexné vzťahy medzi premennými rozdelením dát na segmenty a aproximáciou po častiach lineárnych regresí. Automaticky vyberá dôležité premenné a interakcie, vďaka čomu je vhodná pre vysokodimenzionálne súbory dát. Používa forward-backward algoritmus na pridávanie a odstraňovanie základných funkcií, čím zlepšuje interpretovateľnosť modelu.

Výhody:

- Dokáže zachytiť zložité vzťahy medzi premennými.
- Dokáže spracovať lineárne aj nelineárne vzťahy v údajoch, vďaka čomu je univerzálny pre rôzne typy množín údajov.

Nevýhody:

- Môže byť náchylný na "overfitting"
- Interpretácia modelov MARS môže byť náročná vzhľadom na zložitosť štruktúry modelu s viacerými základnými funkciami. [7]

IV. VÝVOJ MODELU UMELEJ NEURÓNOVEJ SIETI (ANN)

Neurónové siete sa stávajú nevyhnutným nástrojom pre materiálových výskumníkov, keďže dokážu objasniť zložité vzťahy v experimentálnych dátach. Ich využitie vedeckým spôsobom umožňuje analyzovať aj komplexné nelineárne vzťahy. [8]

Kroky pri vývoji modelu ANN:

- Generovanie tréningových dát.

- Výber/rozhodnutie o type siete.
- Výber/rozhodnutie o vstupoch a výstupoch siete.
- Návrh vhodnej konfigurácie siete (príklad konfigurácie vid'. Fig 4.).
- Rozhodnutie o najvhodnejšej stratégii tréningu.
- Spustenie tréningu a validácia siete. [6]




Fig. 4. Príklad konfigurácie ANN s dvoma skrytými vrstvami; počet neurónov v každej vrstve zľava doprava: 12, 8, 6, 1. [8].

V. ZÁVER

Oceliarsky priemysel, ktorý sa vyvíjal paralelne s technologickým pokrokom, nachádza v umelej inteligencii významného spojenca. Aplikácie umelej inteligencie, ako sú strojové učenie a neurové siete, sa stali kľúčovými nástrojmi v rôznych oblastiach od výroby až po plánovanie a riadenie. Napriek výzvam, je jasné, že výhody, ako je zvýšená efektivita a konkurencieschopnosť, prevažujú obmedzenia. Skúmané metódy ponúkajú širokú škálu možností pre rôzne úlohy v oceliarskom priemysle, s každou metódou prichádzajúc so svojimi silnými a slabými stránkami.

Pri vývoji modelov umelej neurónovej siete je dôležité venovať pozornosť správneho výberu vstupov, konfigurácii siete a stratégii tréningu. S využitím týchto moderných technológií môže oceliarsky priemysel efektívne reagovať na súčasné a budúce výzvy a zabezpečiť udržateľný a konkurencieschopný rozvoj.

REFERENCES

- [1] FRUEHAN, R. J. Overview of steelmaking processes and their development. The Making, Shaping and Treating of Steel: Steelmaking and Refining volume., 1998, 2-3. [Online]. Odkaz: <https://www.steelfoundation.org/publications/chapter1.pdf>
- [2] CHAKRABARTI, A. K. (2006). Steel making PHI Learning Pvt. Ltd., 2006.
- [3] PAULIUK, Stefan; WANG, Tao; MÜLLER, Daniel B. Steel all over the world: Estimating in-use stocks of iron for 200 countries. Resources, Conservation and Recycling, 2013, 71: 22-30. [Online]. Odkaz: <https://www.sciencedirect.com/science/article/abs/pii/S0921344912002078>.
- [4] BACKMAN, Jere; KYLLÖNEN, Vesa; HELAAKOSKI, Heli. Methods and tools of improving steel manufacturing processes: Current state and future methods. IFAC-PapersOnLine, 2019, 52.13: 1174-1179 [Online]. Odkaz: <https://www.sciencedirect.com/science/article/pii/S0307904X02000628>
- [5] IIDA, O.; URAKAMI, M.; IWAMURA, T. Applications and evaluation of AI technology in the steel industry. In: Proceedings of IEEE 2nd International Workshop on Emerging Technologies and Factory Automation (ETFA'93). IEEE, 1993. p. 156-163. [Online]. Odkaz: <https://ieeexplore.ieee.org/abstract/document/396416>
- [6] SADA, Samuel O. Improving the predictive accuracy of artificial neural network (ANN) approach in a mild steel turning operation. The International Journal of Advanced Manufacturing Technology, 2021, 112.9: 2389-2398. [Online]. Odkaz: <https://link.springer.com/article/10.1007/s00170-020-06405-4>
- [7] MALLICK, Arpit; DHARA, Subhra; RATH, Sushant. Application of machine learning algorithms for prediction of sinter machine productivity. Machine Learning with Applications, 2021, 6: 100186. [Online]. Odkaz: <https://www.sciencedirect.com/science/article/pii/S2666827021000931>
- [8] SMITH, J. L. Advances in neural networks and potential for their application to steel metallurgy. Materials Science and Technology, 2020, 36.17: 1805-1819. [Online]. Odkaz: <https://journals.sagepub.com/doi/full/10.1080/02670836.2020.1839206>