

Umelá Inteligencia v oceliarskom priemysle

Daniel Haraksim
Technická Univerzita v Košiciach
Fakulta elektrotechniky a informatiky
daniel.haraksim@gmail.com

Abstract—Defekty v konečnom produkte ocele sú spojené s neefektívnosťou v rôznych podprocesoch zapojených. Sekundárna metalurgia (SM), kontinuálne odlievanie (KO) a horúce valcovanie (HV) sú identifikované ako tie, ktoré majú najväčší vplyv, pričom každý z nich má svoje vlastné ukazovatele na určenie týchto neefektívností. Odhad týchto ukazovateľov prostredníctvom modelov riadených údajmi sa ukázal ako cenný nástroj, ktorý umožňuje identifikáciu príčin nízkej produkcie a následnú optimalizáciu operácií smerom k efektívnej produkcii. Táto štúdia analyzuje rôzne modely riadené údajmi o výrobnom procese ocele. Nezávisle pre každý podproces, tieto modely odhadujú relevantné ukazovatele, ako je index odlievateľnosti pre sekundárnu metalurgiu, teplota v bloku pred narovnávaním v kontinuálnom odlievaní a teploty bloku pred horúcim valcom. V metodológii sú použité rôzne metódy výberu charakteristík a stratégie regresie, vrátane nového súborového prístupu s generatívnymi metódami na zvýšenie diverzity predikcie. Všetky tieto modely procesov sú súčasťou metodológie/optimalizačnej platformy procesov, využívajúc globálne metódy ako evolučné algoritmy, čo predstavuje veľký záujem pre oceliarsky priemysel.

Index Terms—Umelá Inteligencia, Predikcia, Oceliarsky priemysel, Oceľ

I. ÚVOD

Oceľový priemysel využíva vysokotechnologické riešenia, vrátane umelého inteligencie, na zlepšenie kvality všetkých svojich produktov. V posledných rokoch oceľový priemysel zažil výrazný nárast požiadaviek na kvalitu ocele používanej pri výrobe, najmä ocele z teplej válcovne na hrubý pás.[4] Tento priemysel je zložitý a generuje veľké množstvo dát, ktoré môžu poskytnúť cenné informácie pri správnom riadení. Údaje pochádzajú z množstva senzorov a sú prenášané po hierarchickom reťazci automatizácie závodu. Tieto údaje sú palivom pre všetky aktivity, od fyzikálnych a metalurgických modelov po optimalizačné stratégie výrobných procesov.

Nespracované údaje samy o sebe neposkytujú informácie a je potrebné z týchto údajov extrahovať poznatky. Je nevyhnutné zvoliť vhodné nástroje na ich spracovanie, uchovávanie, analýzu a interpretáciu - oblasť známa ako veda o dátach. S nárastom komplexity a počtu komponentov výrobných systémov sa extrakcia poznatkov z údajov stáva kľúčovou pre transformáciu priemyselných závodov na inteligentné továrne podporované najnovšími digitálnymi technológiami. Tento vývoj je zvlášť dôležitý pre oceľový priemysel, ktorý sa snaží dosiahnuť vyššiu úroveň kvality svojich výrobkov.

II. PREDIKCIE NA DÁTACH

Predtým ako sa začne s datami pracovať je dôležité si vytknúť kľúčové indikátory výkonu v produkcii ocele

A. Produkcia ocele a meranie kvality

Oceľ sa vyrába hlavne dvoma spôsobmi: elektrickou oblúkovou pecou (EAF), ktorá využíva recyklovanú oceľ (odpad), a integrovanou vysokou pecou (BF)/základnou kyslíkovou pecou (BOF), ktorá získava oceľ z primárneho surového materiálu železného oxidu. Metóda EAF zahŕňa proces odlievania, ktorý je kľúčový pre zabezpečenie kvality.[2] Jednou z metrík používaných na hodnotenie kvality je index odlievateľnosti, ktorý sa pohybuje v rozmedzí od 0 do 10. Tento index je odvodený zo dát procesu získaných počas prevádzky odlievacej strojnice. Hodnotí hladkosť toku ocele v tryskách odlievacej strojnice, čím indikuje prítomnosť oxidových inklúzií.[1] Analýzou časových radov údajov o pozícii uzavretých tyčí odlievacej strojnice index vypočíta celkovú "hodnotu dobrého odlievania". Aj keď táto metóda poskytuje bohaté množstvo údajov, spolieha sa na nepriame merania, čo sa odlišuje od tradičných údajov o čistote, ktoré sú náročnejšie získať.

Po dosiahnutí požadovanej teploty a zloženia v tekutom oceli je nadstavec zvyšovaný na veži a tekutá oceľ je odlievaná do nádoby s viacerými prúdmi. Proces kontinuálneho liatia (CC) je spôsob, ako sa tekutá oceľ tuhne do polotovaru – bilietu, prostredníctvom vodou chladeného otvoreného formovacieho nástroja, sekundárneho chladenia kombinujúceho vodné prúdy a vzduch, elektromagnetického miešania, narovnávanie a rezania polotovaru na požadovanú veľkosť.

Po tuhnutí zostávajú biliety na akýchkoľvek predchádzajúcich chladných lôžkach a presúvajú sa na valcovací stol. Biliety sú zohrievané a valcované cez niekoľko párov valcov, aby sa zredukovala hrúbka a dosiahla požadovaná forma a hrúbka prútov. Kvalita ocele sa zvyčajne zlepšuje, keď podstupuje mechanické napätia pri vysokej teplote.

Nakoniec sú prúty kontrolované zariadeniami na kontrolu kvality, ako sú zariadenia založené na technológii eddy current, na detekciu povrchových trhlín. Po tejto automatizovanej detekcii trhlín nasleduje manuálna kontrola každého prútu s detegovanou trhlinou, pričom sa skúma, či sa trhlina dá opraviť alebo nie.

B. Súborové učenie

V oblasti oceliarskych procesov je použitie efektívnych prediktívnych modelov kľúčové pre optimalizáciu výkonu a zlepšenie efektívnosti. Zvolili sme si stratégiu súborového učenia pre regresnú analýzu v metalurgických procesoch, pričom zdôrazňujeme dôležitosť rozmanitosti a spoľahlivosti pri konštrukcii modelov. Základom súborového učenia zahŕňa tréningovanie viacerých modelov na riešenie toho istého problému a agregáciu ich predikcií na vytvorenie robustnejšieho a presnejšieho celkového modelu.[3]




Fig. 1. Základná stratégia súborového učenia

Cieľom našej analýzy je predpovedať numerické hodnoty, ako sú výkonnostné metriky metalurgických procesov, na základe sady vstupných premenných. Na dosiahnutie toho využívame rôzne regresné techniky, vrátane neurónových sietí.

Kľúčovým aspektom pri tvorbe súborových modelov je rozmanitosť medzi jednotlivými učiacimi sa modelmi, ktoré sa snažia vyriešiť rovnaký problém. Zatiaľ čo tradičné metódy súborov často využívajú techniky náhodného výberu, ako je náhodný výber vzorkovania v tomto papieri sa budeme zaoberať generatívnymi metódami a to nepriamo výber charakteristík.

Tým, že redukuje počet vstupných funkcií modelov, môžeme zmierňovať vplyv problému dimenzionality, ktorý charakterizuje dáta s vysokým počtom funkcií. Napríklad, aplikovaním algoritmov výberu funkcií na konštrukciu podmnožín funkcií z pôvodných dát, môžeme vytvoriť rôznorodé sady modelov. Toto je možnosť, ktorá je tu prezentovaná, kde rozmanitosť je poskytovaná pomocou ne-náhodného výberu funkcií aplikovaním rôznych metód výberu funkcií.

Navrhovaný prístup, nazývaný ako meta-odhadca, je definovaný nasledovne. Majúc sadu funkcií definovaných ako $X = \{x_i\}$, kde $1 \leq i \leq n$ a n je počet funkcií, a majúc $S = \{S_l\}$, kde $1 \leq l \leq L$ a L je počet metód výberu funkcií. Každý S_l stanovuje poradie a triedi množinu funkcií X , vytvárajúc tak L rôznych sád X_l , ktoré definujú rôzny dimenzionálny priestor pre prispôbenie regresného modelu $f(X_l) \rightarrow \hat{y}_l$. [2]

Majúc predikciu každého modelu \hat{y}_l , finálny výstup je

vypočítaný konsenzuálne, ako je definované v rovnici (1):

$$\hat{y} = \sum_{l=1}^L f(X_l) \frac{1}{L} \quad (1)$$

S týmto prístupom sme si zvolili metódu výberu charakteristík a regresívnu paradigmu.

C. Výber charakteristík

Výber charakteristík je kľúčový krok v analýze dát, s cieľom vybrať podmnožinu premenných z veľkého počtu-atočného súboru, ktorá efektívne popisuje dáta a zároveň minimalizuje šum alebo irelevantné premenné. Cieľom je udržať dobrú predikčnú presnosť pri znižovaní zložitosti.

V kontexte výroby ocele, kde existuje mnoho vstupných premenných, sa výber charakteristík vykonáva pomocou filtrovacích metód. Tieto metódy hodnotia premenné na základe určitých kritérií, aby vybrali tie najrelevantnejšie. Kritériá hodnotenia zahŕňajú Pearsonovu koreláciu, vzájomnú informáciu, univariálnu lineárnu regresiu a rekurzívne elimináciu charakteristík. V tomto odseku si popíšeme v krátkosti iba rekurzívnu elimináciu charakteristík

Výberový proces zahŕňa nastavenie prahu (znázorňovaného ako λ), aby sa filtroval určitý percentuálny podiel premenných. Pre túto analýzu je λ vybraná nezávisle pre každú metódu tak, aby sa zachovalo 30 % premenných. Tento prístup pomáha zjednodušiť súbor dát, čo ich robí ľahšie spracovateľnými pre ďalšiu analýzu a modelovanie.[2]

1) *Rekúzná eliminácia charakteristík*: RFE je paŕavý optimalizačný algoritmus, ktorá hľadá najvýkonnejšie charakteristiky subsetu. Opakovane vytvára model, kde každou iteráciou ma ďalší model menej charakteristík až kým ostane iba jedna. Charakteristika sa odoberá podľa kritérií, ktoré ich ohodnocujú a vyberie sa ta najhoršie hodnotená.

D. Regresívna stratégia

1) *Neuronové siete*: Súčasne sú neurónové siete používané v množstve aplikácií, ale vo všetkých prípadoch ich zloženie je v podstate určitý druh siete jednoduchých prepojených procesových prvkov tak, že môžu generovať zložité správanie, pričom toto správanie je určené spojeniami medzi prvkami procesu (často nazývanými ako "váhy").[5] Fungovanie umelej neurónovej siete je podobné biologickým systémom tvoreným neurónmi, takže funkcie sa vyvíjajú kolektívne a paralelne prostredníctvom všetkých prvkov. Umelej neurónovej sieti tvoria jednoduché spracovateľské jednotky, neuróny, a orientované, váhové spojenia medzi týmito neurónmi.

III. EXPERIMENTOVANIE

A. Opisovanie dát

V tomto úseku opíšeme data procesov pri výrobe železa a popíšeme si najdôležitejšie aspekty vstupov a výstupov. Máme 2 dátové typy a to cyklické závislé na čase a asynchrónne závislé na nejakej udalosti pri samotnej výrobe.

1) *Sekundárna Metalurgia*: Cieľom modelu sekundárnej metalurgie (SM) je predpovedať index odlievateľnosti na základe prevádzkových premenných procesu, ktoré sú kľúčové pre kvalitu ocele. Boli použité údaje z deviatich mesiacov ohriev, ktoré boli predmetom predspracovania na zlepšenie presnosti a zobecnenia predikcií. Korekcie a úpravy cyklických údajov sa uskutočnili, pričom sa extrahovali kľúčové charakteristiky, ako je celková spotreba plynu a teploty procesu. Okrem toho sa integrovala informácia o zložení ocele a bola vytvorená nová premenná, ktorá zachytáva aspekty ferrolegerií. S celkovými 54 premennými, vrátane procesových a zloženie ocele, sa vyvinul prediktívny model. Experimentovalo sa s metódami výberu funkcií na zmiernenie premenných a zlepšenie presnosti a zobecnenia modelu, s cieľom budúcej optimalizácie procesu. Supervizované hodnotenie s indexom odlievateľnosti zdôraznilo dôležitosť funkcií pri každej metóde výberu.

2) *Kontinuálne odlievanie*: Kontinuálny odlievací model má za cieľ predpovedať teplotu v strede horného povrchu bloku počas kontinuálneho odlievania, čo je kľúčové pre predchádzanie tvorby trhlín. Keďže priame meranie teploty nie je k dispozícii, tepelný model ju simuluje pomocou rovníc prenosu tepla. Rovnica (2) riadi tento prenos tepla, pričom zohľadňuje faktory ako vlastnosti ocele závislé od teploty. Presnosť modelu bola overená pomocou meraní skenera, pričom sa ukázalo dobré zhodnotenie s iba približne 1% chybou.

Rovnica (2):

$$\frac{\partial^2 T}{\partial x^2} + \frac{\partial^2 T}{\partial y^2} + Q \cdot k(T) = \rho(T) \cdot C_p(T) \cdot k(T) \frac{\partial T}{\partial t}$$

Kde: - T je teplota, - Q je prenesené teplo zo vonkajšieho prostredia, - ρ , C_p a k sú hustota, špecifické teplo a tepelná vodivosť ocele, závislé od teploty, respektíve.

3) *Horúce Valcovanie*: Cieľom modelovania procesu horúceho valcovania bolo predpovedať teplotu bloku pred valcovňou s ohľadom na procesné parametre. Ako bolo spomenuté predtým, kontrola tejto teploty je dôležitá pre predchádzanie tvorbe trhlín počas horúceho valcovania. Keďže táto teplota sa získava nepretržite, boli extrahované priemerné a minimálne teploty bloku na správnu charakterizáciu procesu a boli braté ako cieľové premenné alebo cieľ dvoch modelov, ktoré sa mali vyvinúť. V tomto procese boli vyvinuté dva modely na predpovedanie teploty pred valcovňou. Ako táto teplota sa získava nepretržite, boli extrahované priemerné a minimálne teploty na správnu charakterizáciu procesu. Tieto dve premenné sú veľmi relevantné pre správne valcovanie bloku, preto sú obidve braté ako cieľové premenné modelov, ktoré sa majú vyvinúť.

B. Výsledky

Použitou validačnou metódou bola metóda hold-out s opakovaním, pretože existuje veľká odchýlka medzi

TABLE I
VÝSLEDKY METÓD VÝBERY CHARAKTERISTÍK PRE R^2

Metóda	SM	KO	HV
Pearsonova korelácia	0.42	0.88	0.82
Vzájomná informácia	0.41	0.89	0.82
Univariálna lineárna regresia	0.42	0.9	0.82
Rekurzívna eliminácia	0.42	0.91	0.86

TABLE II
VÝSLEDKY METÓD VÝBERY CHARAKTERISTÍK PRE R^2

Model Regresie	SM	KO	HV
Neuronová sieť	0.43	0.92	0.86
Gradient boosting	0.41	0.94	0.98
Náhodný les	0.29	0.92	0.94

rôznymi simuláciami. Rovnako bol, ako metrika na vyhodnotenie kvality každej aproximácie, použitý koeficient determinácie (nazývaný aj ako R^2), ako aj štatistické testy na zistenie významných rozdielov medzi nimi.

Tabuľka 1 sumarizuje využité metódy na výber charakteristík z datasetu pre jednotlivé procesy výroby železa. Najlepšie výsledky reprezentujú najväčšie číslo pre stĺpec. Vidíme, že rekurzívna eliminácia ma najlepšie výsledky a s touto metódou sme pracovali pri učení súborových modelov

V tabuľke 2 sa vieme dočítať, že pomocou stratégie rekúrviznej eliminácie sme zistili, že algoritmus náhodného stromu podáva najlepšie výsledky za najmenšiu výpočtovú cenu pre proces sekundárnej metalurgie. Napriek tomu má neuronová sieť porovnateľné výsledky pre KO a HV

IV. ZHRNUTIE

Defekty v konečnom produkte ocele sú spojené s neefektívnosťou v rôznych podprocesoch zapojených. SM, KO a HV sú tie, ktoré majú najväčší vplyv, a každý z nich má vlastné ukazovatele na určenie týchto neefektívností. Odhad týchto ukazovateľov prostredníctvom modelov riadených datami je užitočný nástroj, ktorý umožňuje stanoviť príčiny nízkej produkcie a tým optimalizovať operácie smerom k efektívnej produkcii. Pre použitie týchto modelov v prevádzke zariadenia sa vyvíjajú dva vizuálne nástroje na rozhodovanie. Prvým je simulátor ukazovateľov s niektorými vstupmi do procesu, takže operátor sám môže preskúmať priestor parametrov procesu. Druhým je nástroj na vyhľadávanie optimálnych procesných parametrov, pričom nákladová funkcia je založená na vygenerovanom modeli samotnom.

V tejto práci boli analyzované rôzne modely riadené datami o výrobnom procese ocele. Tieto modely boli vyvinuté pre každý podproces nezávisle odhadujú relevantný ukazovateľ, ako je index odlievateľnosti pre sekundárnu metalurgiu, teplota v bloku pred narovnávaním v kontinuálnom odlievaní a teploty bloku pred horúcim valcom. V metodológii boli použité rôzne metódy výberu funkcií a rôzne stratégie regresie. Taktiež je prezentovaný nový prístup založený na stratégii súborových modelov s gen-

eratívny prístupom, pričom sa používa niekoľko metód výberu na generovanie rôznych základných učiacich sa modelov s cieľom dosiahnuť väčšiu diverzitu v predikcii.

Testovalo sa na rôznych stratégiach regresie, založenými na navrhovanej súhrnnej aproximácii. Analyzujúc koeficient determinácie, najjasnejším záverom je, že metóda náhodných lesov dosahuje najlepšie výsledky, dokonca nad neurónovými sieťami.

Nakoniec, všetky tieto modely procesov sú súčasťou metodológie/optimalizačnej platformy procesov, používajúc globálne metódy ako evolučné algoritmy, čo je veľmi zaujímavé pre oceliarsky priemysel.

REFERENCES

- [1] Jere Backman, Vesa Kyllönen, and Heli Helaakoski. Methods and tools of improving steel manufacturing processes: Current state and future methods. *IFAC-PapersOnLine*, 52(13):1174–1179, 2019. 9th IFAC Conference on Manufacturing Modelling, Management and Control MIM 2019.
- [2] Fernando Boto, Maialen Murua, Teresa Gutierrez, Sara Casado, Ana Carrillo, and Asier Arteaga. Data driven performance prediction in steel making. *Metals*, 12(2), 2022.
- [3] Mudasir A Ganaie, Minghui Hu, Ashwani Kumar Malik, Muhammad Tanveer, and Ponnuthurai N Suganthan. Ensemble deep learning: A review. *Engineering Applications of Artificial Intelligence*, 115:105151, 2022.
- [4] A González-Marcos, J Ordieres-Meré, F Alba-Elías, FJ Martínez-de Pisón, and M Castejón-Limas. Advanced predictive system using artificial intelligence for cleaning of steel coils. *Ironmaking & Steelmaking*, 41(4):262–269, 2014.
- [5] Giacomo Pellegrini, Matteo Sandri, Enrico Villagrossi, Sri Challapalli, Luca Cestari, Andrea Polo, and Marco Ometto. Successful use case applications of artificial intelligence in the steel industry. *Iron & Steel Technology (AIST), Digital Transformations*, pages 44–53, 2019.